

Лабораторная работа №1

Платформа FishGrow: исследовательский анализ данных

Дисциплина: «Введение в искусственный интеллект»

Трудоёмкость: 3 академических часа

Ветка Git: lab/01-eda

Формат сдачи: запрос на слияние + отчёт + защита

1 Производственный контекст

Условная платформа FishGrow прогнозирует массу рыбы и контролирует качество входных измерений. До построения модели необходимо понять схему данных, диапазоны значений, ошибки измерения, представленность видов и возможные утечки.

Исходный открытый проект: [исходный репозиторий анализа размерностей рыбы](#). Работа выполняется в собственной копии репозитория или в репозитории курса. Если исходный проект изменился, зафиксируйте адрес, идентификатор коммита и все необходимые изменения инструкции.

Цель

Постройте воспроизводимый исследовательский анализ данных, обнаружьте проблемы качества и сформулируйте проверяемые гипотезы о признаках. Тестовая выборка остаётся закрытой до окончательной проверки модели.

2 Исходная постановка

Целевая переменная — масса объекта. Входные признаки — доступные геометрические измерения и категория вида. Фактическая схема берётся из закреплённой версии репозитория и заносится в паспорт данных: имя поля, смысл, тип, единицы, допустимость пропуска, диапазон и назначение.

Внимание

Названия столбцов и единицы измерения нельзя угадывать по внешнему виду. При неполной документации зафиксируйте риск данных и явно отделите подтверждённый факт от предположения.

3 Порядок выполнения

3.1 Шаг 1. Воспроизведение исходного состояния

Критерии качества

В исходном репозитории нет блокнота Jupyter. Запускаемый файл проекта — `run.py` в корне репозитория. Файл `app.py` создаёт объект веб-приложения Dash и импортируется из `run.py`; отдельно запускать `app.py` не требуется. Собственный исследовательский анализ вы создаёте позднее в новом файле `notebooks/01-eda.ipynb`.

Выполните следующие действия:

1. клонируйте исходный репозиторий, зафиксируйте идентификатор исходного коммита и создайте ветку `lab/01-eda`;
2. убедитесь, что в корне репозитория присутствуют `run.py`, `app.py`, каталоги `pages/` и `assets/`;
3. создайте чистое окружение и установите зависимости проекта. В исходном репозитории для этого предусмотрены `Pipfile` и `Pipfile.lock`;
4. из корня репозитория запустите приложение командой `python run.py`;

5. откройте в браузере локальный адрес, который выведен в терминале, и проверьте главную страницу и страницу прогнозирования;
6. зафиксируйте результат запуска: версию Python, версии ключевых библиотек, команду запуска и возникшие ошибки. Если старые зависимости несовместимы с текущим окружением, сначала сохраните исходную ошибку, затем документируйте минимальные изменения, необходимые для запуска;
7. после проверки исходного приложения создайте собственный блокнот `notebooks/01-eda.ipynb`. Именно в нём выполняются шаги 2–7 этой лабораторной работы;
8. сохраняйте только необходимые изменения; кэши и крупные результаты добавляйте в `.gitignore`.

Внимание

Запуск `python run.py` нужен для проверки воспроизводимости исходного проекта. Он не заменяет собственный исследовательский анализ данных. Исходный репозиторий содержит веб-приложение и описание проведённого автором анализа, поэтому свой анализ необходимо оформить отдельно.

3.2 Шаг 2. Паспорт данных

Сформировать паспорт данных по единому шаблону из общих требований к практикуму. Для каждого поля явно указать:

- исходное имя столбца и его предметный смысл;
- тип данных и единицы измерения;
- назначение: признак, целевая переменная, группирующий признак, идентификатор или служебное поле;
- допустимость пропусков и предполагаемую причину их появления;
- диапазон допустимых значений и проверки физического смысла.

Проверка физического смысла включает положительность длины и массы, согласованность нескольких измерений одной рыбы и отсутствие невозможных комбинаций полей. Укажите единицу независимого наблюдения и выясните, могут ли строки относиться к одному объекту, партии, ферме или моменту времени.

3.3 Шаг 3. Автоматическая проверка качества

Реализовать функции или повторно используемые ячейки, проверяющие:

- форму таблицы, типы данных, дубликаты строк и идентификаторов;
- пропуски, бесконечности и невозможные значения;
- согласованность связанных геометрических измерений;
- редкие категории и дисбаланс видов;
- почти одинаковые строки;
- уникальные поля, способные стать идентификаторами или источниками утечки.

3.4 Шаг 4. Визуализация

В собственном блокноте Jupyter представить не менее шести содержательных графиков:

1. распределение целевой переменной в исходной и логарифмической шкале;
2. численность и распределение целевой переменной по видам;
3. матрицу парных графиков выбранных признаков;
4. корреляционную матрицу числовых признаков с оговоркой о нелинейных связях;

5. график пропусков или иных показателей качества данных;
6. визуализацию выбросов с указанием конкретных строк;
7. дополнительный график, проверяющий собственную гипотезу.

Каждый график должен иметь заголовок, подписи осей, единицы измерения и текстовый вывод. График без интерпретации не считается завершённым анализом.

3.5 Шаг 5. Пропуски и выбросы

Для числового признака вычислить границы межквартильного размаха **IQR** — межквартильный размах:

$$[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR], \quad IQR = Q_3 - Q_1.$$

Дополнительно вычислить устойчивую стандартизованную оценку через медианное абсолютное отклонение **MAD**:

$$z_i^{MAD} = 0.6745 \frac{x_i - \text{med}(x)}{MAD}, \quad MAD = \text{med} |x_i - \text{med}(x)|.$$

Здесь x_i — значение признака для строки i , Q_1 и Q_3 — первый и третий квартили. Сравните списки подозрительных строк. Для каждой существенной аномалии выберите и обоснуйте действие: исправить по источнику, удалить, ограничить крайнее значение заданным квантилем, добавить признак-флаг, оставить или исключить только из конкретного эксперимента.

Внимание

Выброс и ошибка — разные понятия. Самая крупная рыба может быть наиболее ценным наблюдением для проверки обобщающей способности модели.

3.6 Шаг 6. Гипотезы о признаках

Проверить не менее двух гипотез. Одна гипотеза должна опираться на физический смысл. Например, построить приближённую оценку объёма

$$V_{\text{прибл}} = L \cdot H \cdot W,$$

где L , H и W — осмысленно выбранные длина, высота и ширина. Затем сравнить связь $V_{\text{прибл}}$ с массой по видам. Целевую переменную запрещено использовать при вычислении нового входного признака.

Для категориального признака опишите способ кодирования и поведение модели при появлении нового вида. Для сильно коррелированных длин обсудите мультиколлинеарность. Автоматическое удаление признаков по одному порогу корреляции требует отдельного обоснования.

3.7 Шаг 7. Разбиение и проверка утечек

До моделирования предложить правило разделения данных на обучающую, проверочную и тестовую выборки. При наличии зависимых групп использовать групповое разбиение. Составить таблицу не менее чем из пяти возможных каналов утечки: статистики всей таблицы, повторные строки, идентификатор, постфактум измерение, ручной подбор по тестовой выборке.

4 Минимальный кодовый каркас

```

1 from pathlib import Path
2 import pandas as pd
3
4 DATA_PATH = Path("data/fish.csv")
5 df = pd.read_csv(DATA_PATH)
6
7 assert not df.empty
8 assert df.columns.is_unique
9 assert len(df) == len(df.drop_duplicates()) # либо описать дубликаты
10
11 quality = pd.DataFrame({
12     "dtype": df.dtypes.astype(str),
13     "missing": df.isna().sum(),
14     "unique": df.nunique(dropna=False),
15 })
16 print(quality)

```

5 Материалы сдачи

Материалы сдачи

- notebooks/01-eda.ipynb — собственный исследовательский анализ с воспроизводимым выполнением сверху вниз;
- src/data-checks.py или равнозначный модуль проверок;
- reports/lab01-report.md с паспортом, графиками, выводами и проверкой утечек;
- reports/figures/ с подписанными изображениями;
- обновлённый README.md с командами запуска;
- запрос на слияние с содержательным описанием и разделом об использовании ИИ.

6 Критерии приёмки

Элемент	Баллы
Корректная схема, проверки качества, визуализации, анализ пропусков и выбросов, обоснованные выводы и отсутствие критической утечки	40
Воспроизводимый собственный блокнот Jupyter, зафиксированный запуск run.py, версии окружения, две гипотезы и журнал решений	20
Ветка, не менее четырёх содержательных атомарных коммитов, запрос на слияние и рецензирование	20
Файл README, паспорт данных, подписи графиков и структура отчёта	10

Защита: объяснение IQR, MAD, одного графика и выбранного разбиения	10
Всего	100

Критерии качества

Работа готова к защите, если блокнот запускается в чистом ядре, каждый вывод следует из показанных данных, а список аномалий содержит ссылки на строки и обоснованные действия.

7 Контрольные вопросы

1. Почему корреляция между признаками не доказывает причинную связь?
2. Чем механизмы полностью случайных пропусков (MCAR), условно случайных пропусков (MAR) и пропусков, зависящих от скрытого значения (MNAR), различаются с точки зрения обработки?
3. Почему IQR и MAD не дают автоматического основания для удаления наблюдения?
4. Как предварительная обработка, настроенная на всей таблице, создаёт утечку данных?
5. Как зависимые строки меняют эффективный размер выборки?
6. Как проверить, что визуализация не скрыла редкую, но критичную группу?

Дополнительная часть

Построить автоматический отчёт в HTML как дополнение к собственному анализу; добавить формальную схему проверки данных и тест, который срабатывает при изменении единиц или диапазона ключевого поля.