

Лабораторная работа №2

Платформа FishGrow: прогностическая модель и MLflow

Дисциплина: «Введение в искусственный интеллект»

Трудоёмкость: 4 академических часа

Ветка Git: lab/02-regression

Формат сдачи: запрос на слияние + отчёт + защита

1 Производственный контекст

На основе данных, исследованных в работе №1, требуется построить воспроизводимую модель массы рыбы, сравнить линейный и нелинейный подходы и зафиксировать эксперименты. Исходный ориентир: [исходный репозиторий регрессионной модели](#).

Цель

Соберите единую цепочку предварительной обработки и модели, честно сравните решения по средней квадратичной ошибке (MSE), средней абсолютной ошибке (MAE) и коэффициенту детерминации R^2 , зарегистрируйте конфигурации в MLflow и сформулируйте ограничения прототипа.

2 Метрики и порядок оценивания

Для тестовой выборки размера n вычисляются

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

Здесь y_i — истинная масса, $\hat{y}_i$ — прогноз, $\bar{y}$ — средняя масса, n — число объектов. MSE сильнее штрафует крупные ошибки; MAE измеряется в единицах целевой переменной; отрицательный R^2 означает результат хуже константного прогноза среднего значения.

Внимание

Метрики разных моделей сравнимы при одинаковом составе тестовой выборки, одинаковой предварительной обработке и одной версии данных. Округление результата не исправляет ошибочное разбиение.

2.1 Разбиение

1. заморозить тестовую выборку до подбора признаков и гиперпараметров;
2. выбирать модель по перекрёстной проверке внутри обучающей выборки;
3. при наличии групп использовать GroupKFold или отдельную отложенную группу;
4. кодировщик категорий, заполнение пропусков и масштабирование настраивать внутри каждой итерации перекрёстной проверки как единую цепочку преобразований;
5. хранить индексы частей выборки или детерминированное правило их получения.

3 Обязательные эксперименты

3.1 E0. Наивное базовое решение

Сравнить модели с прогнозом среднего или медианы обучающей выборки. Этот ориентир показывает, приносит ли сложная модель практическую пользу.

3.2 E1. Линейная регрессия

Воспроизвести базовое решение исходного проекта, затем перенести предварительную обработку в ColumnTransformer. Проверить остатки, неоднородность дисперсии и мультиколлинеарность. При сильной асимметрии целевой переменной отдельно проверить вариант $\log(1 + y)$ с корректным обратным преобразованием и метриками в исходной шкале.

3.3 E2. Регуляризованная линейная модель

Добавить гребневую регрессию, реализованную классом Ridge, или модель с совместной L1- и L2-регуляризацией. Параметр регуляризации выбирать по перекрёстной проверке. Объяснить, какие коэффициенты сравнимы только после согласованного масштабирования.

3.4 E3. Нелинейная модель

Добавить как минимум один обоснованный ансамбль: гистограммный градиентный бустинг, случайный лес либо другой подход. Ограничить область поиска небольшой заранее заданной сеткой или распределением и зафиксировать вычислительный бюджет.

3.5 E4. Эксперимент с группой признаков

Использовать тот же набор данных и то же разбиение, что и в остальных экспериментах этой лабораторной. Переносить строки или значения из набора данных работы №1 не требуется. Из работы №1 переносится только **идея** осмысленной группы признаков или производного признака.

Сформулировать конкретный вопрос и сравнить две версии одного и того же метода. Например:

- добавить производный геометрический признак $V_{proxy} = L \cdot H \cdot W$ и проверить, меняются ли MSE, MAE и R^2 ;
- заменить несколько сильно связанных измерений длины одним выбранным измерением и оценить изменение качества;
- исключить категорию вида рыбы и измерить её вклад в качество прогноза.

Во всех вариантах способ разбиения, состав обучающей и тестовой выборки, предварительная обработка и правило оценивания должны оставаться одинаковыми.

Внимание

Добавление производных геометрических признаков может усилить мультиколлинеарность в линейной модели. Это часть эксперимента, которую нужно проверить. Сравните корреляции числовых признаков и устойчивость коэффициентов. Если новый признак почти дублирует исходные измерения, рассмотрите два варианта: **заменить** им исходную группу признаков либо использовать гребневую регрессию, которая устойчивее к сильной взаимосвязи признаков. Итог эксперимента оценивается по качеству на проверочных данных, а не по величине отдельных коэффициентов линейной модели.

4 Рекомендуемая цепочка обработки

```
1 from sklearn.compose import ColumnTransformer
2 from sklearn.impute import SimpleImputer
3 from sklearn.pipeline import Pipeline
4 from sklearn.preprocessing import OneHotEncoder, StandardScaler
5 from sklearn.linear_model import Ridge
6
7 numeric = Pipeline([
8     ("imputer", SimpleImputer(strategy="median")),
9     ("scale", StandardScaler()),
10 ])
11 categorical = Pipeline([
12     ("imputer", SimpleImputer(strategy="most_frequent")),
13     ("onehot", OneHotEncoder(handle_unknown="ignore")),
14 ])
15 preprocess = ColumnTransformer([
16     ("num", numeric, numeric_columns),
17     ("cat", categorical, categorical_columns),
18 ])
19 model = Pipeline([
20     ("preprocess", preprocess),
21     ("regressor", Ridge(alpha=1.0)),
22 ])
```

5 Учёт экспериментов в MLflow

Каждый запуск должен иметь уникальное имя и содержать:

- параметры разбиения, начальное значение генератора, список признаков и версию данных;
- класс модели и гиперпараметры;
- среднее и стандартное отклонение метрик перекрёстной проверки, а также итоговые MSE, MAE и R^2 на тестовой выборке;
- таблицу прогнозов и остатков для тестовой выборки;
- графики остатков и зависимости прогноза от истинного значения;
- идентификатор коммита и версию окружения в тегах;
- сохранённую цепочку обработки лучшей модели и паспорт модели.

```
1 import mlflow
2 import mlflow.sklearn
3
4 with mlflow.start_run(run_name="ridge-volume-features"):
5     mlflow.log_params(config)
6     model.fit(X_train, y_train)
7     prediction = model.predict(X_test)
8     mlflow.log_metrics({
9         "test_mse": mean_squared_error(y_test, prediction),
10        "test_mae": mean_absolute_error(y_test, prediction),
11        "test_r2": r2_score(y_test, prediction),
12    })
13     mlflow.sklearn.log_model(model, artifact_path="model")
```

6 Анализ ошибок

Обязательно:

1. построить график остатков и найти систематические зоны ошибки;
2. показать не менее пяти крупнейших абсолютных ошибок вместе с исходными признаками;
3. сравнить MAE по видам и хотя бы одному диапазону размера;
4. проверить отрицательные и физически невозможные предсказания;
5. определить, связана ли ошибка с данными, моделью или постановкой задачи;
6. предложить следующий эксперимент и заранее сформулировать ожидаемый результат.

7 Минимальные тесты

- индексы обучающей и тестовой выборки не пересекаются;
- цепочка обработки принимает строку с неизвестной категорией;
- число прогнозов равно числу входных строк, все значения конечны;
- метрики на зафиксированном контрольном примере совпадают с ручным расчётом;
- сохранённая цепочка обработки после загрузки воспроизводит прогноз в заданном допуске.

8 Материалы сдачи

Материалы сдачи

- `src/train.py`, `src/evaluate.py` и файлы конфигурации;
- блокнот Jupyter только для анализа, без скрытой обязательной логики обучения;
- локальный журнал MLflow либо экспорт метаданных и снимок структуры запусков;
- `reports/lab02-report.md` с таблицей E0–E4 и анализом ошибок;
- `models/model-card.md` с паспортом модели;
- тесты и файл README с командами;
- запрос на слияние и тег Git v0.1 после приёмки.

9 Критерии приёмки

Элемент	Баллы
Корректная цепочка обработки и разбиение, E0–E3, метрики, анализ остатков и ошибок	40
Эксперимент с группой признаков, перекрёстная проверка, записи MLflow, версии и воспроизводимый сценарий	20
Ветка, атомарные коммиты, запрос на слияние, рецензирование и тег v0.1	20

Файл README, паспорт модели, таблица экспериментов и инструкции	10
Защита: интерпретация MSE, MAE, R^2 , регуляризации и одной ошибки	10
Всего	100

10 Контрольные вопросы

1. Почему масштабирование и заполнение пропусков должны настраиваться внутри каждой итерации перекрёстной проверки?
2. Как интерпретируется отрицательный R^2 на тестовой выборке?
3. Чем гребневая регрессия отличается от обычного метода наименьших квадратов?
4. Почему важность признака в дереве не является доказательством причинного влияния?
5. Что нужно сохранять вместе с моделью?
6. Какие признаки укажут на сдвиг распределения после внедрения?

Дополнительная часть

Добавить доверительные интервалы методом повторной выборки с возвращением, сравнить интервалы прогноза либо подготовить Docker-сценарий пакетного применения модели с проверкой схемы входа.